

Team Project: Open Data Source Analysis & Planning

- Eksplorasi sumber data terbuka (Open Data):
 - Data Instansi (FIFA)
 - Dataset dari Kaggle
 - Public APIs (API-Football.)
 - Open research data (Git Repo)
- Analisis karakteristik dan kualitas data
- Membuat peta alur data untuk integrasi
- Dokumentasi requirement dan rencana penggunaan
- Output: Project blueprint dan documentation

Open Data Source Analysis & Planning Project

Project Information

Project Name : Prediksi Pertandingan Sepak Bola Pada Piala Dunia 2026

Version: 1.0

1. Executive Summary

1.1. Project Overview

- **Tujuan Project:** Mengembangkan model machine learning untuk memprediksi hasil pertandingan sepak bola piala dunia 2026 serta penyajian data pertandingan FIFA World Cup 1930 - 2022 secara ringkas dan terstruktur dalam bentuk statistik deskriptif dan visualisasi sederhana.
- **Scope Project:** Pengolahan dan penyajian data pertandingan Piala Dunia dan liga besar yang mencakup informasi umum dan detail informasi seperti kapten tuan rumah, jumlah kartu merah dll.
- **Expected Outcomes:** Prediksi hasil pertandingan dan ringkasan statistik utama, Tabel dan grafik sederhana untuk visualisasi data, Dokumentasi analisis data dan blueprint pemanfaatan dataset.

- **Timeline:** 19 Februari - 26 April 2026

1.2. Stakeholders

- **Project Owner:** PT Rajawali Citra Televisi Indonesia (RCTI)
- **Team Members:**
 - **Data Engineer:**
 1. Muhammad Rosyid Ridlo Abdillah
 2. Rayyan Afif
 - **Data Analyst:** Erlangga Deanda Chandra Setya
 - **Project Manager:** Alvina Nur Laila Anggraini
- **End Users:**
 - Pengamat sepak bola
 - Narator/Komentator
 - Penulis naskah acara
 - Tim kreatif

2. Data Source Analysis

2.1. Data Instansi (FIFA)

Source Details

- **Dataset Name:** FIFA/Coca-Cola World Rankings
- **URL/Access Point:** <https://www.fifa.com/en/world-rankings>
- **Data Owner:** FIFA (Federation Internationale de Football Association)
- **Update Frequency:** Bulanan

Data Analysis

- **Format Data:** HTML
- **Volume Data:** 3 MB hingga 8 MB

- **Time Coverage:** 2018 - Sekarang

Data Quality:

- **Completeness:** 100%
- **Accuracy:** Very High (langsung dari website resmi)
- **Consistency:** Good (format terstruktur)
- **Timeliness:** Umumnya diperbarui setiap bulan. Namun, frekuensi pembaruan ini sangat sinkron dengan kalender *FIFA Matchday* atau turnamen besar.

2.2. Dataset Kaggle

Source Details

- **Dataset Name:** Football - FIFA World Cup, 1930 - 2022
- **UR/Access Point:** [Football - FIFA World Cup, 1930 - 2022](#)
- **Creator/Publisher:** Petro Ivaniuk
- **Last Update:** 2023

Data Analyst

- **Format Data:** CSV
- **Size & Dimensions:** 174 KB
- **Data Fields:**
- **Quality Metrics:**
 - Missing Values: null
 - Data Types: String, Integer, Float
 - Consistency: High
 - Documentation Quality: High

2.3. Public APIs

Source Details

- **API Name:** API-Football
- **Endpoint URL:** <https://v3.football.api-sports.io/>
- **Provider:** API-SPORTS
- **Authentication Method:** API Key melalui HTTP Headers

API Analysis

- **Response Format:** JSON (JavaScript Object Notation).
- **Rate Limits:** Paket Gratis (Free): Dibatasi maksimal 100 request per hari dan tidak boleh lebih dari 10 request per menit.
- **Reliability:** Sangat tinggi. Layanan ini dirancang untuk produksi skala besar dengan pembaruan data livescore setiap 15 detik.
- **Documentation Quality:** Sangat baik dan komprehensif.
- **Cost:** Menggunakan model Freemium

2.4. Open Research Data

Source Details

- **Dataset Name:** StatsBomb Open Data
- **Repository:** <https://github.com/statsbomb/open-data>.
- **Research Institution:** StatsBomb (Perusahaan Analitik Data Olahraga yang secara resmi membuka sebagian database komersial mereka untuk tujuan riset akademik dan proyek portofolio data science).


- **Publication Date:** Pembaruan berkelanjutan (Continuous Update). Data Piala Dunia 2022 dirilis secara publik pada awal tahun 2023, sementara data liga historis ditambahkan secara berkala.

Data Analysis

- **Format & Structure:** Terutama menggunakan format .json bersarang (nested JSON). Data dibagi menjadi tiga struktur hierarki utama: competitions.json (daftar liga/turnamen), matches.json (metadata pertandingan), dan events.json.
- **Data Volume:** Relatif besar untuk ukuran teks (ratusan Megabyte hingga lebih dari 1 Gigabyte).
- **Data Quality:** Kualitas Enterprise (Sangat Tinggi).
- **Citation Requirements:** Atribusi Terbuka: Menggunakan lisensi khusus untuk penggunaan non-komersial dan riset. Peneliti atau developer diwajibkan mencantumkan teks pengakuan (acknowledgement) berbunyi: "Data provided by StatsBomb". Jika data ini diubah menjadi antarmuka visual (misalnya memetakan arah tendangan di atas gambar lapangan sepak bola dalam jurnal atau artikel Medium), pengguna diwajibkan untuk menyertakan logo StatsBomb di dalam grafik visual tersebut.

3. Data Flow Mapping

3.1. Data Integration Architecture



3.2. ETL Process Design

- **Extraction Methods:**

- Data diekstrak dari API-Football menggunakan metode REST API dengan format JSON.
- Data tim nasional diperoleh melalui endpoint `/teams` untuk mendapatkan informasi tim nasional dari berbagai negara.

- Data pemain tim nasional diperoleh melalui endpoint `/players/squads` yang berisi daftar pemain aktif pada setiap tim nasional.
- Proses ekstraksi dilakukan menggunakan bahasa pemrograman Python dengan library `requests`.
- **Transformation Rules:**
 - Melakukan filter data untuk hanya mengambil tim yang berstatus sebagai tim nasional (`national = True`).
 - Menggabungkan data skuad pemain dan data statistik pemain berdasarkan `player_id`.
 - Mengubah format rating pemain dari tipe string menjadi numerik (`float`) agar dapat digunakan untuk analisis lebih lanjut.
- **Loading Procedures:**
 - Data yang telah dibersihkan dan ditransformasikan dimuat ke dalam dataset terstruktur menggunakan Pandas DataFrame.
 - Dataset hasil pengolahan disimpan dalam format CSV dengan nama file `players.csv`.
 - Data yang telah tersimpan dapat digunakan untuk proses analisis, visualisasi, maupun integrasi ke sistem data warehouse pada tahap berikutnya.
- **Scheduling:**
 - Proses ETL dijalankan secara batch berdasarkan kebutuhan pengambilan data.
 - Mengingat API-Football Free Plan memiliki batasan 100 request per hari, proses ekstraksi dilakukan secara bertahap untuk menghindari melebihi batas penggunaan API.
 - Pembaruan data dapat dilakukan secara berkala, misalnya satu kali per minggu atau setiap awal musim kompetisi.

3.3. Diagram Arsitektur RAG

